

Логистик регрессийн үнэлгээний тайлан

1. Асуудал ба дата

Энэхүү ажилд харилцагч default буюу зээлийн үүргээ биелүүлэх эсэхийг логистик регрессийн загвараар таамаглах асуудлыг авч үзсэн. Өгөгдөл нь нийт 1000 орчим ажиглалт, 8 шинж чанартай бөгөөд target хувьсагч нь default эсэхийг 0 болон 1 утгаар илэрхийлнэ. Ангийн харьцаа бүрэн тэнцвэртэй биш тул зөвхөн accuracy бус precision, recall, F1 болон ROC-AUC үзүүлэлтүүдийг хамтад нь ашиглан загварыг үнэлсэн.

2. Загвар ба сургалт

Загварын хувьд StandardScaler болон LogisticRegression-ийг Pipeline ашиглан нэгтгэсэн. LogisticRegression-ийн $C=1.0$, $\text{max_iter}=1000$ параметруудийг ашигласан. Feature scaling нь шинжүүдийн хэмжээсийн ялгааг багасгаж, логистик регрессийн сургалтыг тогтвортой хийхэд тусална. Харин ангиллын босгыг default утгаар 0.50-аас эхлүүлж, 0.35, 0.25, 0.15 зэрэг босгууд дээр мөн харьцуулсан. Зардлын шинжилгээнд FN-ийн зардал FP-ээс 10 дахин өндөр тул threshold-ийг зөвхөн 0.5 гэж тогтоохгүйгээр нийт зардлыг харгалзан үзсэн.

3. Үр дүн

Босго		Precision	Recall	F1	AUC
0.50	0.919	0.466	0.618	≈ 0.871	
0.35	0.830	0.603	0.698	≈ 0.871	
0.25	0.701	0.644	0.671	≈ 0.871	
0.15	0.486	0.712	0.578	≈ 0.871	

Pipeline загварын тестийн ROC-AUC нь ойролцоогоор **0.871**, харин 0.50 босгон дээр precision **0.919** байсан. Босгыг 0.15 хүртэл бууруулахад recall **0.712** болж өссөн боловч precision **0.486** болж буурсан. Энэ нь босго буурахад илүү олон default-ийг илрүүлдэг боловч false positive мөн нэмэгддэгтэй холбоотой.

5-fold StratifiedKFold cross-validation-ийн дундаж ROC-AUC нь ойролцоогоор **0.870 ± 0.019** гарсан.

4. Шийдвэр

Зардлын шинжилгээгээр FN нэг бүр 10 нэгж, FP нэг бүр 1 нэгжийн зардалтай гэж үзсэн. Иймээс threshold-ийг бууруулахад FN буурч болох боловч FP нэмэгдэн нийт

зардалд нөлөөлнө. Хүлээгдэж буй үр дүнгээр нийт зардал хамгийн бага байх босго нь ойролцоогоор **0.15**, нийт зардал нь **265** орчим байна. Тиймээс энэхүү зардлын нөхцөлд 0.15 босгыг ашиглах хувилбарыг сонгосон.

5. Хязгаарлалт

Нэгдүгээрт, өгөгдлийн 8 шинж чанар нэргүй тул тэдгээрийн бизнесийн бодит утгыг тайлбарлах боломж хязгаарлагдмал. Хоёрдугаарт, өгөгдөл нь синтетик буюу зохиомол өгөгдөл учраас бодит банкны хэрэглээнд шууд хэрэглэх боломжгүй. Мөн threshold-ийн сонголт нь өгөгдсөн FN болон FP зардлын нөхцөлөөс хамаардаг тул өөр байгууллага, өөр зардлын нөхцөлд өөр босго сонгогдож болно.

6. Дараагийн алхам

Дараагийн шатанд class imbalance-ийн нөлөөг судлахын тулд class_weight параметрийг туршиж, мөн SMOTE ашигласан хувилбарыг харьцуулж болно. Үүний зэрэгцээ ROC-AUC-аас гадна PR-AUC үзүүлэлтийг ашиглан default ангиллыг илрүүлэх чадварыг илүү нарийвчлан үнэлэх боломжтой.

https://github.com/Mandarmaa/W4_machine_learning